

BrainScanNet: Diagnósticos Inteligentes Para Tumores Cerebrais Usando IA

Gabriel Carvalho

`gdc2@cin.ufpe.br`

CCSA - UFPE

Recife, Brasil

Leandro Freitas

`l11lf@cin.ufpe.br`

CIn - UFPE

Recife, Brasil

Lucas Sales

`lfasm@cin.ufpe.br`

CIn - UFPE

Recife, Brasil

23 de março de 2025

Programação

- 1 Introdução
- 2 Ferramentas Utilizadas
- 3 Banco de Dados
- 4 Análise Exploratória dos Dados
 - Proporção Dataset
 - Amostragem de Ressonâncias
 - Resolução das Imagens
 - Tamanho das Imagens e Canal de Cores
 - Ruído e Brilho
 - Pré-processamento
- 5 Modelo BrainScanNet
 - Estrutura da Rede
- 6 Hiperparâmetros do Treinamento
- 7 Desempenho do Modelo
 - Fase de Treinamento
 - Fase de Teste
- 8 Conclusão

Introdução

Introdução

- * Tumores do SNC representam 1,4% a 1,8% de todos os tumores malignos (INC).
- * Estudo aborda Glioma, Meningioma, Tumores Pituitários.
- * Objetivo: Desenvolver e avaliar um modelo CNN para melhorar a precisão do diagnóstico e detecção precoce. Utilizando Ressonância magnética.

Ferramentas Utilizadas

Linguagem de Programação, IDE e Bibliotecas

* Linguagem de Programação:

Python

* Ambiente de Desenvolvimento:

Google Colab

* Bibliotecas:

1) Manipulação de Dados:

Pandas

Kaggle (para acesso ao Dataset)

2) Matemática e Estatística:

NumPy

3) Machine Learning e Deep Learning:

Scikit-learn

PyTorch

4) Geração de Gráficos:

Matplotlib

Banco de Dados

Base de Dados

* Dataset: Brain Tumor MRI Dataset (Kaggle).


Link: <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>

* Contém imagens de ressonância magnética (MRI) rotuladas de tumores cerebrais.

Análise Exploratória dos Dados

Proporção Dataset

Divisão do Dataset: Treino vs Teste



Distribuição das Classes (Treino)




Figura: Divisão do Dataset

Treino: 81.3% (5712 imagens)

Teste: 18.7% (1311 imagens)

Classes balanceadas no treino: 25% cada.

Amostragem de Ressonâncias




Figura: Amostras de Imagens (3 por classe)

Resolução das Imagens




Figura: Dispersão da Resolução

- * Variação na resolução.
- * Necessidade de redimensionamento para CNN.

Canal de Cores e Tamanho das Imagens

* Conversão para escala de cinza (1 canal) para redução da complexidade computacional.


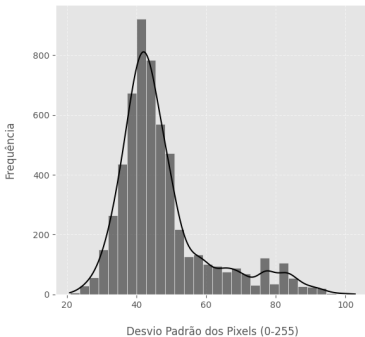


Figura: Tamanho das Imagens (KB)

* Tamanho: Outliers e necessidade de padronização.

Ruído e Brilho

Distribuição do Desvio Padrão dos Pixels



Distribuição do Brilho das Imagens

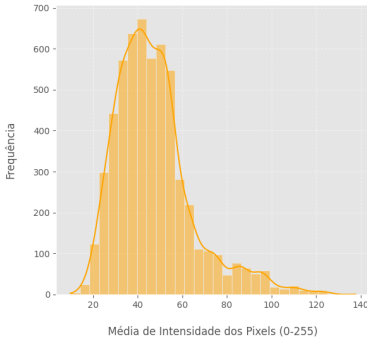



Figura: Histogramas de Desvio Padrão e Média

- * Variação no contraste e brilho.
- * Normalização (Z-score) como solução.


Exemplos de Imagens

Comparação de Imagens (Desvio Padrão vs. Brilho)


Baixo Contraste (Std)




Baixo Contraste (Std)




Alto Contraste (Std)




Alto Contraste (Std)




Baixo Brilho



Baixo Brilho



Alto Brilho



Alto Brilho




Figura: Imagens com Diferentes Características

Pré-processamento

- * Conversão para 1 canal (escala de cinza).
- * Redimensionamento: 224x224 pixels.
- * Normalização Z-score.
- * Rotação aleatória (até 5 graus).

Treinamento e Validação

- * Divisão: 80% treino, 20% validação.
- * Batch size: 32.
- * Transformações replicadas na base de teste.

Modelo BrainScanNet

Modelo BrainScanNet




Figura: Arquitetura do Modelo

- * 4 blocos convolucionais (Conv -> BN -> ReLU -> MaxPool).
- * Camadas totalmente conectadas (FC).

Hiperparâmetros do Treinamento

Hiperparâmetros

- * Otimizador: Adam.
- * Learning rate inicial: 0.001.
- * ReduceLROnPlateau.
- * Dropout: 50%
- * Épocas: 25.

Desempenho do Modelo

Desempenho do Modelo durante o Treinamento

Métrica	Valor
Train Loss	1.78%
Val Loss	18.99%
Train Acc	99.32%
Val Acc	95.88%

Tabela: Resultados Finais

Desempenho do Modelo durante o Treinamento

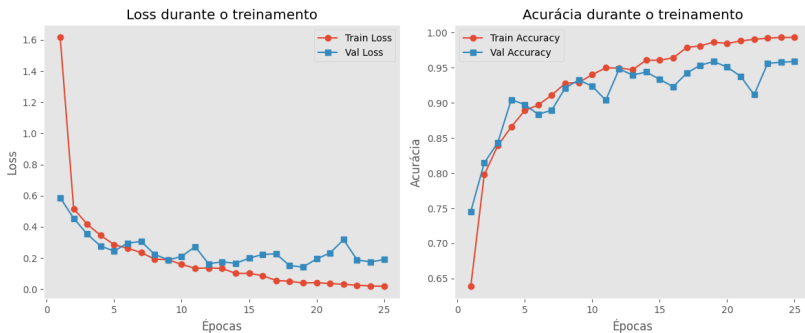


Figura: Loss e Acurácia

Etapa de Teste




Figura: Matriz de Confusão

F1-Score

* F1-Score: A métrica F1-Score é calculada como a média harmônica da precisão (precision) e recall:

$$F1-Score = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}$$

- * F1-Score do BrainScanNet: 97.32%
- * Bom equilíbrio entre acurácia e recall.
- * Modelo com boa performance em novas observações.

Visão do Modelo

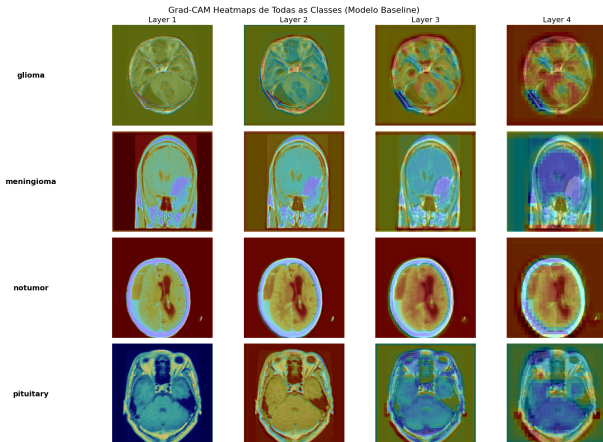


Figura: Heatmap do Modelo

Conclusão

Conclusão

- * CNNs podem ser úteis na saúde pública.
- * Modelo BrainScanNet promissor para detecção precoce.
- * Potencial para auxiliar médicos.
- * Contribuição para a melhoria da detecção e tratamento de tumores.